

# Desenvolvimento e Validação de um Framework de Inteligência Artificial para Segmentação de Imagens Médicas


Guilherme Felipe Ramos Cruz

Orientador:

Dr. Edson Luiz Pontes Perger


# O Desafio da Segmentação em Imagens Médicas

- **Processo Crítico:** Essencial para diagnóstico, planejamento terapêutico e monitoramento de doenças
- **Processo Manual:** Lento, exaustivo e sujeito à variabilidade entre especialistas.
- **Volume de Dados:** Crescente volume de exames (TC, RM) excede a capacidade de análise puramente humana.



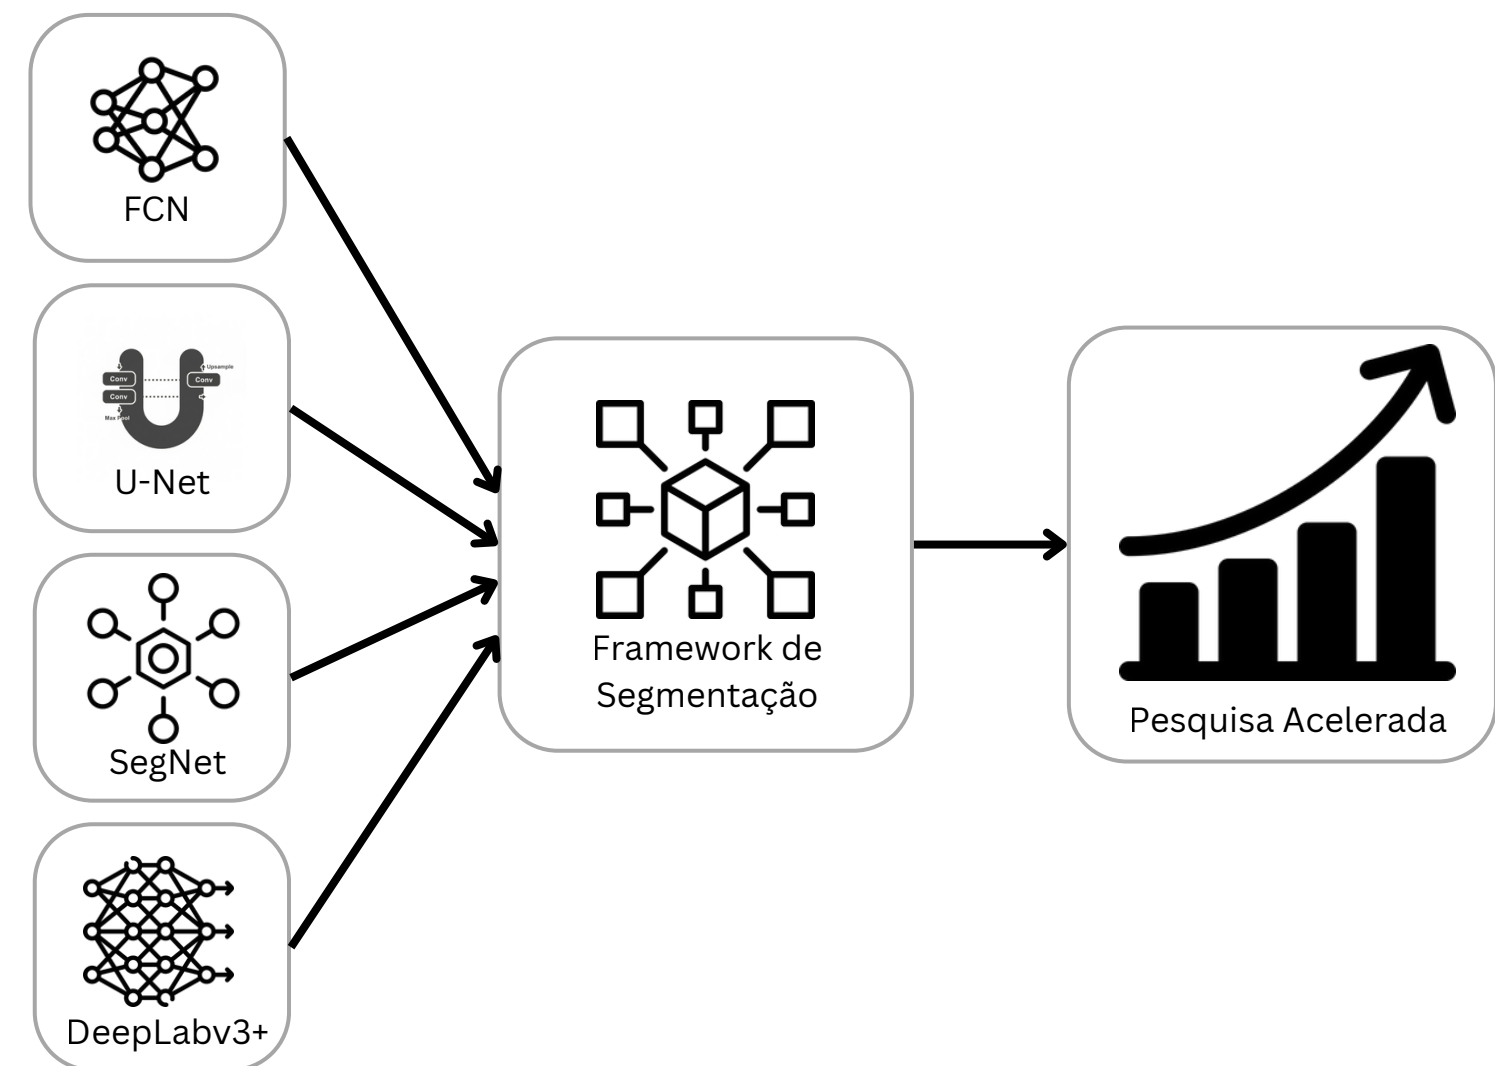
# A Solução: Um Framework Validado e Reutilizável.

- **Lacuna Atual:** Modelos de IA existem, mas pesquisadores precisam implementá-los "do zero" a cada projeto, dificultando a comparação e demandando tempo técnico.
- **Proposta:** Desenvolver, validar e consolidar as 4 principais arquiteturas em um framework pronto para uso.




# A Solução: Um Framework Validado e Reutilizável.

- **Lacuna Atual:** Modelos de IA existem, mas pesquisadores precisam implementá-los "do zero" a cada projeto, dificultando a comparação e demandando tempo técnico.
- **Proposta:** Desenvolver, validar e consolidar as 4 principais arquiteturas em um framework pronto para uso.




# O Resultado do Projeto: O Produto Final.

- **O que é?** Um conjunto de códigos, modelos pré-treinados e documentação que permite a qualquer pesquisador possa criar seu próprio modelo de IA personalizado.
- **Para quem?** Pesquisadores e alunos da UNESP.
- **Qual o benefício?**
  - **Acelera a Pesquisa:** Reduz drasticamente o tempo de desenvolvimento técnico.
  - **Padroniza a Avaliação:** Permite comparações justas entre diferentes abordagens.
  - **Democratiza o Acesso:** Diminui a barreira técnica para o uso de IA em saúde.



# PADRONIZAÇÃO REUTILIZAÇÃO






# Objetivos

- **Objetivo Geral:** Consolidar 4 modelos de IA (FCN, U-Net, SegNet, DeepLabv3+) em um framework para segmentação de imagens médicas.
- **Objetivos Específicos:**

1. Implementar as arquiteturas em ambiente unificado.




2. Treinar e otimizar usando o dataset público BraTS.



3. Avaliar o desempenho com métricas padrão (Dice e IoU).



4. Estruturar o código-fonte em um framework documentado e reutilizável.



# Metodologia

## Dados:

Dataset público Brain Tumor Segmentation (BraTS).

<https://www.kaggle.com/datasets/awsaf49/brats2020-training-data>



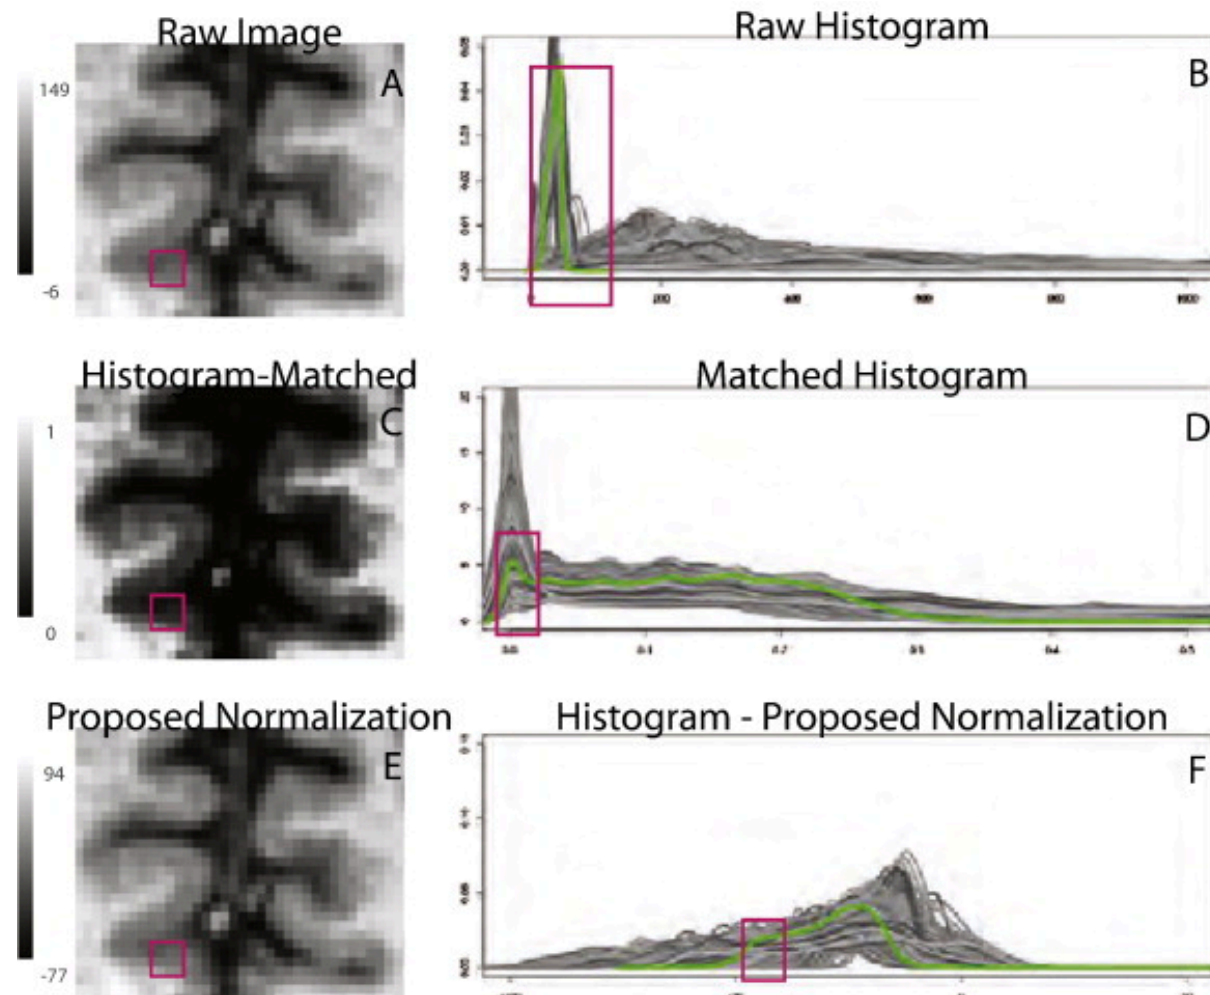


# Metodologia

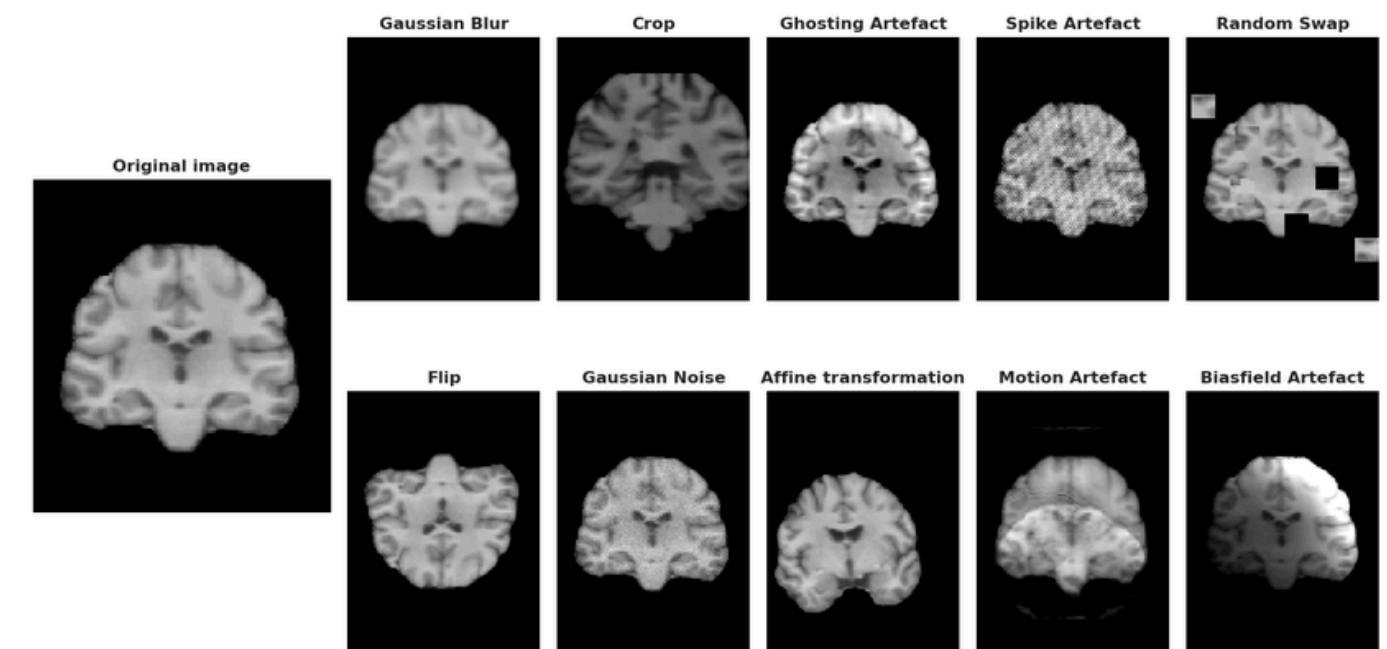
## Pré-processamento

### Normalização

#### Z-score



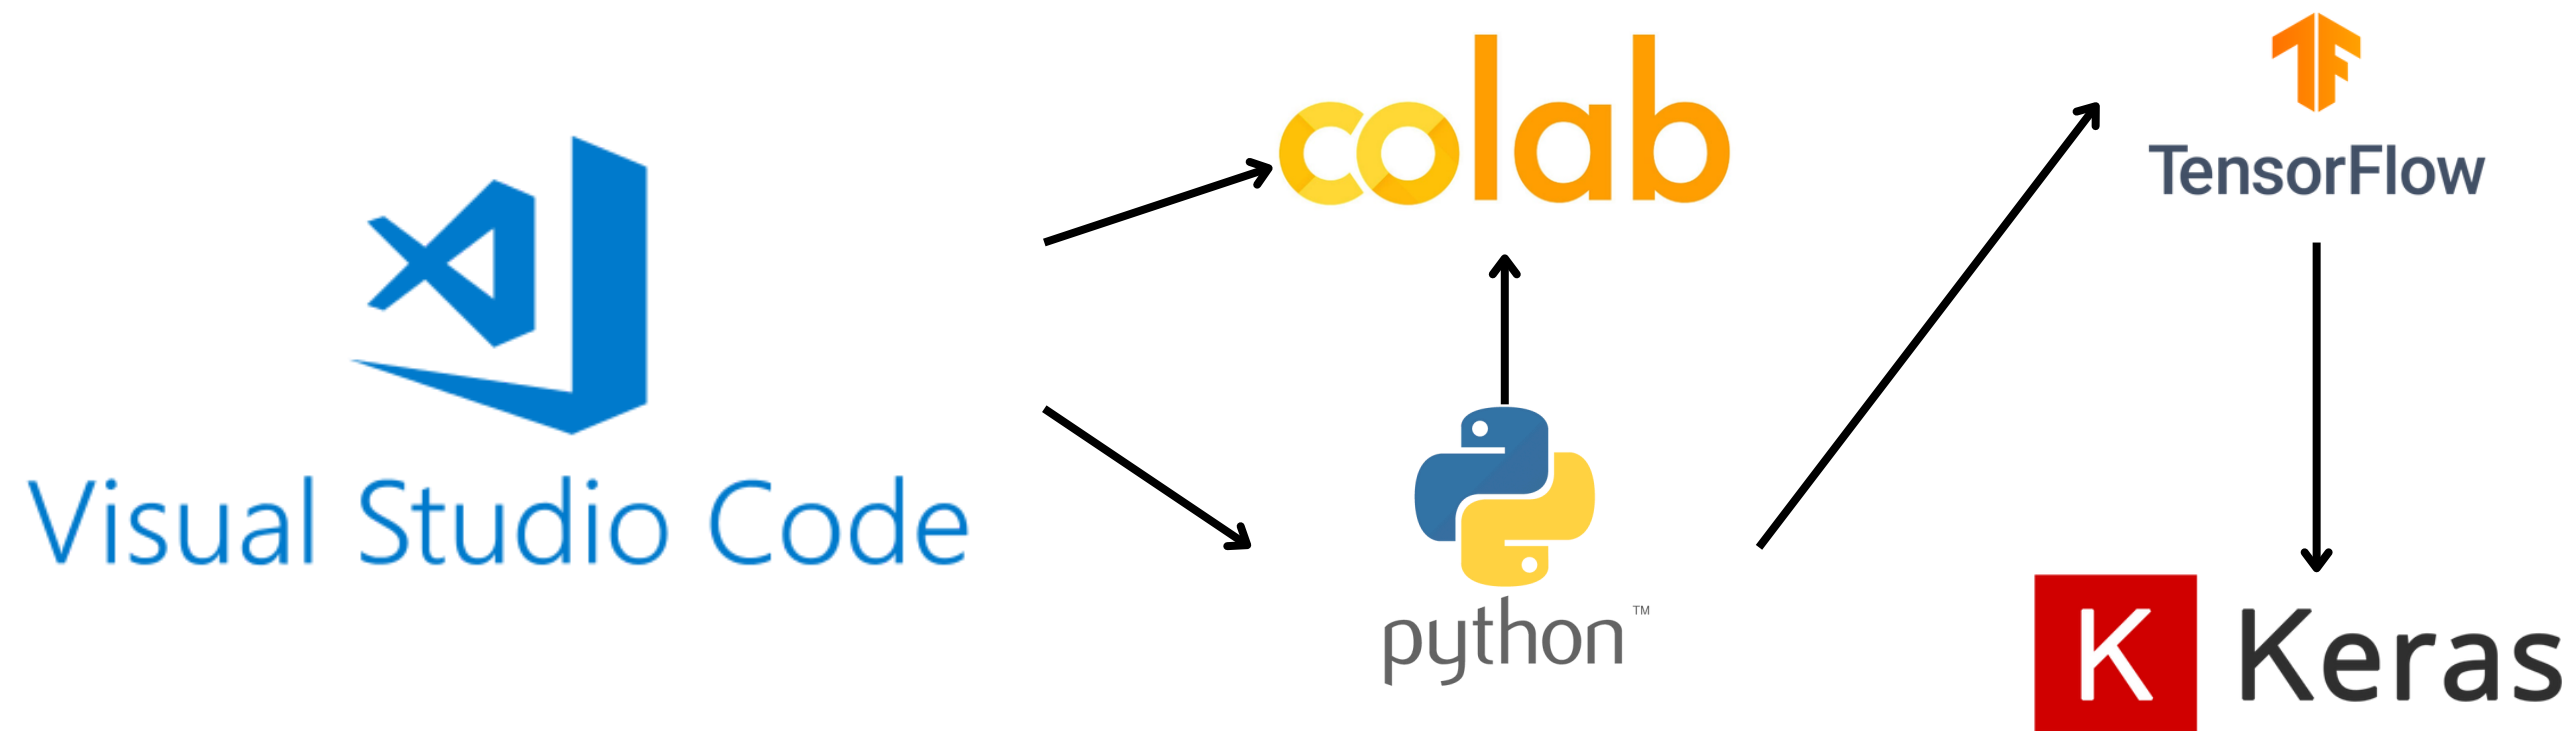
### Data Augmentation



[https://www.researchgate.net/publication/267930907\\_Statistical\\_normalization\\_techniques\\_for\\_magnetic\\_resonance\\_imaging](https://www.researchgate.net/publication/267930907_Statistical_normalization_techniques_for_magnetic_resonance_imaging)

# Metodologia


**Ambiente:**




# Metodologia

## Análise:

Coeficiente de  
Similaridade de Dice (DSC)




Interseção sobre União  
(IoU)




# Metodologia

DATASET BraTS



Pré-processamento




Implementação e Treinamento



Avaliação Comparativa



# Cronograma de Execução



# Obrigado!

Agradeço a oportunidade e a atenção da banca.

Estou à disposição para perguntas.

Guilherme Felipe Ramos Cruz  
ti.guilhermecruz@gmail.com



# Obrigado!

Agradeço a oportunidade e a atenção da banca.

Estou à disposição para perguntas.

Guilherme Felipe Ramos Cruz  
ti.guilhermecruz@gmail.com